

Sinh Unit Test Tự Động Cho Hàm Java

Dùng GPT-4o-mini: paired comparison với Student Benchmark Tests

PL Lê Thế Khang	DG Huỳnh Cao Phước	LR Phạm An Khang
MS Nguyễn Thị Như Ý	RW Đỗ Long Vỹ	

SE1944 - Nhóm 01

Ngày bảo vệ: cập nhật theo lịch thực tế

Vấn Đề Nghiên Cứu

Vì sao Branch Coverage chưa đủ để đánh giá unit test do LLM sinh ra?

Bối cảnh

Viết unit test thủ công tốn thời gian và dễ bỏ sót edge cases.

LLM test generation là hướng SOTA giúp tự động hóa một phần quy trình kiểm thử.

Hiện trạng

GPT-4, LLaMA-3 và GPT-4o-mini đã cho thấy khả năng sinh test khá tốt.

Nhưng coverage cao không đồng nghĩa với fault detection tốt.

Research GAP

GAP-D: thiếu paired comparison giữa GPT-4o-mini và Student Benchmark trên cùng HumanEval-Java functions.

GAP-M: cần dùng Mutation Score bên cạnh Branch Coverage để tránh đánh giá lệch.

Ý nghĩa: cần cơ sở khoa học để biết AI hỗ trợ được sinh viên đến mức nào trước khi dùng trong học tập hoặc chấm bài.

Tổng Quan Related Work & GAP Mapping

Bảng bằng chứng gộp: N = 39 papers sau khi loại trùng

SỐ PAPER

39

paper đã tổng hợp

GAP-D CHÍNH

0

paper làm paired Java student baseline

GAP-M PHỤ

12

paper ủng hộ dùng 2 metric

ID	Paper	Bằng chứng chính	Hạn chế
005	Al-Tse'23	TestPilot: 52.8% Branch Coverage	Không đo Mutation Score
010	Huang'26	ULT: 30.22% BC, 40.21% MS	Chưa có paired baseline với sinh viên
019	Multi-Agent'26	Tương đương test case sinh viên	Trễ và tốn API token
024	AgoneTest'25	Có đánh giá GPT-4o-mini trên Java	Compile ban đầu còn thấp
026	MutGen'26	100% coverage vẫn có thể chỉ 4% MS	Mutation feedback tốn tài nguyên

Bốn Câu Hỏi Nghiên Cứu (Research Questions)

Đánh giá theo ngưỡng, paired comparison và độ tin cậy kép

RQ1 Branch Coverage

Trung vị BC-AI $\geq 30.22\%$

One-sample Wilcoxon

RQ2 Mutation Score

Trung vị MS-AI $\geq 4.0\%$ sản và $\geq 40.21\%$ mục tiêu

One-sample Wilcoxon

RQ3 AI vs Student

So sánh paired BC/MS trên cùng hàm

Paired Wilcoxon, two-tailed

RQ4 Độ tin cậy kép

BC $\geq 30.22\%$ và MS $\geq 4.0\%$ cho $>50\%$ số hàm

Exact Binomial Test

Đóng góp chính: cùng 50 hàm được đo hai lần - test do GPT-4o-mini sinh và Student Benchmark test - bằng cùng pipeline JaCoCo/PIT.

Pipeline Thực Nghiệm

Sáu bước tự động từ lọc dataset đến kiểm định thống kê

1 Lọc Dataset

N=50; CC 5-16

3 Hậu xử lý

Tách code JUnit 4

5 Đo metric

JaCoCo + PIT

2 LLM Prompting

GPT-4o-mini;
temp=0

4 Compile + Repair

Maven; sửa 1 vòng

6 Thống kê

scipy
Wilcoxon/Binomial

Quy tắc lỗi: test vẫn fail sau 1 vòng repair sẽ nhận 0% coverage và 0% mutation score, nhưng vẫn báo riêng compile status.

Dataset HumanEval-Java & Student Baseline

Thiết kế paired comparison có kiểm soát trên cùng các hàm Java

BENCHMARK GỐC

163

hàm Java

MẪU CHỌN

50

CC từ 5 đến 16

SO SÁNH

2x

AI test vs Student test

Vì sao chọn mẫu này?

Các hàm thuật toán, chuỗi và toán học khá độc lập.

CC 5-16 tránh hàm quá dễ nhưng vẫn đủ khả thi.

Repo local đã có correct Java code và benchmark tests.

Thiết kế paired baseline

Student Benchmark tests được đo trên đúng cùng target functions.

Cả hai test suite dùng chung Maven, JaCoCo và PIT pipeline.

RQ3 dùng chênh lệch paired, không chỉ so sánh trung bình tổng.

Cấu Hình LLM & Đo Lường

Sinh test có tính tái lập, công cụ cố định, ground truth tự động

Sinh test bằng LLM

MODEL	gpt-4o-mini-2024-07-18
TEMPERATURE	0
TOP_P	1
MAX_TOKENS	2000
PROMPTING	Zero-shot prompt có cấu trúc cho JUnit 4

Đo lường

BRANCH COVERAGE	JaCoCo v0.8.7+
MUTATION SCORE	PIT / PiTest v1.7.4+
MUTATORS	DEFAULTS
GROUND TRUTH	mã Java trong humaneval.correct
IAA	Không áp dụng: đo bằng metric tự động

Điểm neo tái lập: cố định model version, prompt template, temperature, raw outputs, compile logs và metric CSV có timestamp.

Cách Diễn Giải Kết Quả

Chỉ reject H0 khi p-value đạt và metric đi đúng hướng mong đợi

RQ	Tiêu chí	Reject H0 khi...
RQ1	BC >= 30.22%	p < 0.05 và median >= ngưỡng
RQ2a	MS >= 4.0%	p < 0.05 và median >= ngưỡng sàn
RQ2b	MS >= 40.21%	p < 0.05 và median >= mục tiêu
RQ3	AI vs Student	p < 0.05 cho chênh lệch paired BC/MS
RQ4	Dual success > 50%	p < 0.05 và tỷ lệ mẫu > 50%

Double Positive BC và MS đạt

AI tests mạnh cả về cấu trúc và logic.

Mixed BC đạt, MS fail

Coverage Blindness: code được chạy nhưng không bắt lỗi tốt.

Double Negative BC và MS fail

Zero-shot GPT-4o-mini cần prompt hoặc feedback mạnh hơn.

Rủi Ro Về Độ Tin Cậy & Cách Giảm Thiểu

Các Threats to Validity chính được nêu rõ và có cách xử lý

Internal

Model drift

Cố định API model version và temperature = 0.

External

Phạm vi dataset

Giới hạn kết luận ở standalone Java unit-level functions.

Construct

Metric chưa đủ rộng

Báo cáo compile/pass status cùng với BC và MS.

Conclusion

N nhỏ / lỗi compile

Dùng N=50 và 1-round self-repair; báo cáo mẫu bị loại.

Ý chính: kể cả kết quả âm tính vẫn có giá trị, vì GAP paired student-baseline hiện vẫn chưa được giải quyết.

Timeline, Vai Trò & Chi Phí

Kế hoạch thực hiện gọn trong tuần 5-10

PL Khang

Tiến độ, review, blockers

DG Phước

Dataset và baseline

LR An Khang

API runner và logs

MS Như Ý

JaCoCo/PIT và thống kê

RW Vỹ

Related work và báo cáo

W5

Proposal + dataset + test API

W6

Nộp proposal + bảo vệ gate

W7

Pilot run 10% mẫu

W8

Full experiment + metrics

W9-10

Báo cáo cuối + presentation

CHI PHÍ API

~\$1.33

khoảng 33,000 VND

Chi phí ước tính gồm token input/output của gpt-4o-mini và phần dự phòng cho pilot + one-round repair.

Q&A

Câu hỏi phản biện dự kiến

"Vì sao nhóm chọn các ngưỡng 30.22% và 4.0%?"

Trả lời ngắn

30.22% là average Branch Coverage trên benchmark ULT trong GS010.

4.0% là mutation-score floor cảnh báo từ GS026: coverage cao vẫn có thể bắt lỗi logic rất yếu.

40.21% là target Mutation Score từ GS010, dùng làm ngưỡng tham chiếu mạnh hơn.

Các ngưỡng được chọn theo Case 2 trong barem RBL để bảo đảm cơ sở thực nghiệm.

Backup: bảng Related Work đầy đủ trong `evidence-table-merged.md`