


Zero-shot GPT-4o-mini tạo được 14 test suite chạy hợp lệ trên 63 hàm Java

Đánh giá bằng execution validity, branch coverage, mutation score và paired comparison với EvoSuite.

Lê Thế Khang | Huỳnh Cao Phước | Phạm An Khang | Nguyễn Thị Như Ý | Đỗ Long Vỹ

API trả text không đồng nghĩa test suite hợp lệ

Đánh giá cần tách generation, compilation, execution và fault detection.



Ranh giới diễn giải

EvoSuite là comparator kỹ thuật có thể tái lập, không phải student-written data. So sánh với student benchmark được hoãn vì chưa có đo lường per-function tương thích.


Năm RQ liên kết quality threshold với execution reality

RQ3 chỉ dùng SUT mà GPT và EvoSuite đều pass.

-
- RQ1** GPT có vượt 30.22% branch coverage không?
-
- RQ2** GPT có vượt mutation-score floor 4.00% và target 40.21% không?
-
- RQ3** Ở budget 1, 3, 5 phút, GPT có khác EvoSuite trên cùng SUT không?
-
- RQ4** Có hơn một nửa SUT đạt đồng thời cả hai threshold không?
-
- RQ5** Failure pattern nào ngăn test đạt các threshold?

Một pipeline cố định đo cả hai tool trên cùng 63 SUT


Zero-shot generation được ghi riêng với execution validity và metric quality.



Archive EvoSuite 1/3/5 phút không được generate lại; chúng được đo lại bằng cùng Maven/JaCoCo/PIT pipeline trên Temurin JDK 8.

Execution validity là giới hạn chính của zero-shot protocol

Chỉ 14 test suite pass sau generation và một repair cycle được phép.



ASSERTION FAILURES

47

95.9% số suite invalid

COMPILE FAILURES


2

4.1% số suite invalid

Kết luận: API success không được tính là test-suite success.

Kết quả full corpus không đạt các giả thuyết đã định trước

Số liệu gồm toàn bộ 63 target, không chỉ executable subset.



AGGREGATE BRANCH COVERAGE

18.90%

144 / 762 branches

AGGREGATE MUTATION SCORE


16.21%

135 / 833 mutants

RQ1, cả hai RQ2 threshold và RQ4 đều không được hỗ trợ ($p > 0.05$). Dual success: 13 / 63 = 20.63%.

Không có GPT–EvoSuite comparison nào significant sau Holm

RQ3 dùng 14 branch pairs và 13 mutation pairs vì chỉ ghép suite pass ở cả hai tool.



CLOSEST COMPARISON

5m mutation

raw p = 0.062509

AFTER ADJUSTMENT

p = 0.375053

not statistically significant

Không được tổng quát hóa pass-conditioned GPT mean sang full 63-SUT corpus.

Bottleneck là oracle validity, không phải khả năng API trả code

Kết quả âm cho zero-shot reliability vẫn cho thấy workflow cần kiểm soát chặt.

Evidence supports

- Gate bằng compilation và execution.
- Báo branch coverage kèm mutation score.
- Dùng EvoSuite theo budget đã nêu.

Evidence does not support

- GPT zero-shot luôn sinh test Java hợp lệ.
- GPT tương đương EvoSuite trong mọi setting.
- Bất kỳ suy luận nào về student-written tests.

Bước tiếp theo: repair feedback và student baseline

Nghiên cứu này thiết lập ranh giới hiện tại và baseline có thể tái lập cho follow-up experiment.

CURRENT RESULT 14 / 63 GPT suites executable	TECHNICAL BASELINE 63 / 63 EvoSuite suites pass mỗi budget	INFERENCE 0 / 6 RQ3 significant after Holm
---	---	---

Future work

- Repair assertion bằng execution feedback.
- Lập lại trên benchmark/model khác.
- Đo student suites bằng cùng pipeline trước khi so sánh.